



Προγραμματιστική εργασία: Σημασιολογική ανάκτηση

Χρήστος Ρομπόκος, 3220171

Φάση 1 – Baseline – Κλασική ανάκτηση

Η ακόλουθη αναφορά συνοψίζει την ανάπτυξη και αξιολόγηση ενός συστήματος ανάκτησης πληροφοριών για τη συλλογή IR2025. Το σύστημα βασίζεται στην μηχανή αναζήτησης Elasticsearch, χρησιμοποιώντας το πιθανοτικό μοντέλο κατάταξης BM25 για την ευρετηρίαση και ανάκτηση ερωτημάτων από μία συλλογή 18.316 κειμένων.

Για την διαδικασία ευρετηρίασης χρησιμοποιήθηκε ο Standard Analyzer της Elastic Search, ο οποίος εκτελεί κανονικοποίηση σε πεζά γράμματα, tokenization με βάση την απλή γραμματική και αφαίρεση συνηθισμένων αγγλικών stopwords. Αυτό διασφαλίζει ότι η μηχανή αναζήτησης εστιάζει σε όρους με υψηλή σημασιολογική αξία, ενώ παραμένει ανεξάρτητη από τα πεζά και κεφαλαία γράμματα. Η συνάρτηση ομοιότητας της διαδικασίας ανάκτησης είναι ο αλγόριθμος BM25, ο οποίος βελτιώνει τα παραδοσιακά μοντέλα TF-IDF, καθώς λαμβάνει υπ' όψιν τις συχνότητες των όρων και τα μήκη των κειμένων. Δηλαδή, δεν δίνεται μεγαλύτερη αξία σε κείμενα με επαναλαμβανόμενες λέξεις ή πολύ μεγάλο μήκος. Έτσι, τα συνοπτικά και σχετικά έγγραφα κατατάσσονται κατάλληλα δίπλα σε μεγαλύτερα κείμενα.

Η αξιολόγηση του συστήματος πραγματοποιήθηκε χρησιμοποιώντας το εργαλείο trec_eval για να συγκριθούν τα ανακτημένα αποτελέσματα με το δοθέν αρχείο qrels.txt σε τρία βάθη ανάκτησης ($k=20, 30, 50$). Για την εκτέλεση του results_k20, το σύστημα πέτυχε Mean Average Precision (MAP) 0.5237, με Precision@5 0.7400 και Precision@20 0.5100. Όταν το βάθος ανάκτησης αυξήθηκε στο results_k30, το MAP αυξήθηκε στο 0.5602, ενώ οι τιμές Precision@k παρέμειναν σταθερές. Η τελική αξιολόγηση στο results_k50 έφτασε στο υψηλότερο MAP, 0.5685. Αυτή η τάση δείχνει ότι, ενώ η κατάταξη των κορυφαίων αποτελεσμάτων παραμένει σταθερή, η αύξηση του αριθμού των ανακτημένων εγγράφων βελτιώνει σημαντικά την ανάκληση, καταγράφοντας σχετικά κείμενα που τοποθετήθηκαν

χαμηλότερα στη λίστα κατάταξης.

```
C:\Windows\System32\cmd.exe
Microsoft Windows [Version 10.0.26200.7462]
(c) Microsoft Corporation. All rights reserved.

C:\Users\30695\Desktop\40ETOS\706MHNO\Systhmata_Anakthshs\ergasial\ToRun>trc_eval.exe -m map -m P.5,10,15,20 qrels.txt resul
ts_k20.txt
3 [main] trc_eval 11108 find_fast_cwd: WARNING: Couldn't compute FAST_CWD pointer. Please report this problem to
the public mailing list cygwin@cygwin.com
map          all      0.5237
P_5          all      0.7400
P_10         all      0.6400
P_15         all      0.5867
P_20         all      0.5100

C:\Users\30695\Desktop\40ETOS\706MHNO\Systhmata_Anakthshs\ergasial\ToRun>trc_eval.exe -m map -m P.5,10,15,20 qrels.txt resul
ts_k30.txt
3 [main] trc_eval 8620 find_fast_cwd: WARNING: Couldn't compute FAST_CWD pointer. Please report this problem to
the public mailing list cygwin@cygwin.com
map          all      0.5602
P_5          all      0.7400
P_10         all      0.6400
P_15         all      0.5867
P_20         all      0.5100

C:\Users\30695\Desktop\40ETOS\706MHNO\Systhmata_Anakthshs\ergasial\ToRun>trc_eval.exe -m map -m P.5,10,15,20 qrels.txt resul
ts_k50.txt
3 [main] trc_eval 17604 find_fast_cwd: WARNING: Couldn't compute FAST_CWD pointer. Please report this problem to
the public mailing list cygwin@cygwin.com
map          all      0.5685
P_5          all      0.7400
P_10         all      0.6400
P_15         all      0.5867
P_20         all      0.5100
```

Μια λεπτομερής ανάλυση ερωτήματος προς ερώτημα αποκαλύπτει ότι η απόδοση του συστήματος επηρεάζεται σε μεγάλο βαθμό από την εξειδίκευση των όρων του ερωτήματος. Τα ερωτήματα υψηλής απόδοσης (πράσινο πλαίσιο), όπως τα Q06 και Q09, πέτυχαν πολύ υψηλές βαθμολογίες που ξεπερνούσαν το 0.90, πιθανότατα γιατί περιείχαν σπάνιες λέξεις, όπως "5GEx" και "MaaS4EU". Αυτοί οι σπάνιοι όροι έχουν υψηλή διακριτική ισχύ, επιτρέποντας στην BM25 να εντοπίζει εύκολα τα σωστά κείμενα. Αντίθετα, ερωτήματα με χαμηλότερη απόδοση (κόκκινο πλαίσιο), όπως τα Q05 και Q07, βασίζονταν σε πιο ευρεία ορολογία. Αυτοί οι όροι εμφανίζονται συχνά σε ολόκληρη τη συλλογή, δημιουργώντας σημασιολογικό "θόρυβο" που δυσκολεύει το σύστημα να διακρίνει τα κατάλληλα κείμενα. Σε περιπτώσεις όπως τα Q08 και Q10 (κίτρινο πλαίσιο), το σύστημα παρουσίασε υψηλή ακρίβεια στα πρώτα ανακτηθέντα κείμενα με P@5 1.0000, παρόλο που το MAP ήταν χαμηλότερο, δείχνοντας ότι η συνάρτηση κατάταξης ιεραρχεί πρώτα τα πιο σχετικά κείμενα.


map	Q05	0.2909
P_5	Q05	0.4000
P_10	Q05	0.5000
P_15	Q05	0.4667
P_20	Q05	0.4000
map	Q06	0.7577
P_5	Q06	1.0000
P_10	Q06	0.9000
P_15	Q06	0.8667
P_20	Q06	0.7000
map	Q07	0.2436
P_5	Q07	0.6000
P_10	Q07	0.5000
P_15	Q07	0.3333
P_20	Q07	0.2500
map	Q08	0.7045
P_5	Q08	1.0000
P_10	Q08	0.6000
P_15	Q08	0.6667
P_20	Q08	0.5500
map	Q09	0.9318
P_5	Q09	1.0000
P_10	Q09	1.0000
P_15	Q09	0.8667
P_20	Q09	0.9000
map	Q10	0.7772
P_5	Q10	1.0000
P_10	Q10	0.7000
P_15	Q10	0.4667
P_20	Q10	0.3500

Κατά τη φάση ανάπτυξης, διεξήχθη μια πειραματική εκτέλεση χρησιμοποιώντας ένα Porter Stemmer για να προσδιοριστεί εάν η αποκοπή των καταλήξεων των λέξεων θα βελτίωνε την απόδοση. Ωστόσο, αυτό είχε ως αποτέλεσμα μια σημαντική πτώση στο MAP σε περίπου 0.50. Αυτή η υποβάθμιση της απόδοσης συνέβη επειδή ο stemmer ήταν πολύ επιθετικός, συγχέοντας σπάνια ακρωνύμια και συγκεκριμένες ορολογίες με λέξεις με τις οποίες δεν ταίριαζαν εννοιολογικά.


Τα αποτελέσματα επιβεβαιώνουν ότι μια βασική εφαρμογή της BM25 είναι ιδιαίτερα αποτελεσματική για την ανάκτηση κειμένων, ιδιαίτερα όταν τα ερωτήματα χρησιμοποιούν συγκεκριμένη τεχνική ορολογία. Μελλοντικές εργασίες θα μπορούσαν να διερευνήσουν τεχνικές επέκτασης ερωτημάτων για να βοηθήσουν με ευρύτερα ερωτήματα χαμηλής απόδοσης, διατηρώντας παράλληλα την υψηλή ακρίβεια που παρατηρείται σήμερα στα αποτελέσματα με την υψηλότερη κατάταξη.

Επιπλέον screenshots:

Screenshot από την σύνδεση στην μηχανή αναζήτησης Elastic Search:



Screenshot από την εκτέλεση του κώδικα:



Ως πηγές χρησιμοποιήθηκαν η ιστοσελίδα elastic.co για την χρήση της Elasticsearch, η ιστοσελίδα rafaelglater.com για την χρήση των εντολών command line της trec_eval και οι σημειώσεις του μαθήματος.