



Προγραμματιστική εργασία: Σημασιολογική ανάκτηση

Χρήστος Ρομπόκος, 3220171

Φάση 3 - Υβριδικό σύστημα ανάκτησης: συνδυασμός κλασικής και σημασιολογικής ανάκτησης

Η ακόλουθη αναφορά συνοψίζει την ανάπτυξη και αξιολόγηση ενός συστήματος ανάκτησης πληροφοριών για τη συλλογή IR2025. Στην πρώτη φάση της εργασίας προσεγγίσαμε αυτό το πρόβλημα με κλασική ανάκτηση με την χρήση του πιθανοτικού μοντέλου BM25 και την μηχανή αναζήτησης Elasticsearch, ενώ στην δεύτερη φάση κάναμε σημασιολογική ανάκτηση με την χρήση Transformers και ευρετηρίου FAISS. Στην τρίτη φάση, όμως, συνδυάζουμε τα δύο παραπάνω συστήματα με σκοπό να εκμεταλλευτούμε τα πλεονεκτήματα του καθενός.

Υλοποιούμε το υβριδικό σύστημα ανάκτησης για να πάρουμε τα θετικά στοιχεία κάθε μοντέλου, δηλαδή την ταχύτητα του ευρετηρίου της Elasticsearch και την σημασιολογική αναζήτηση που προσφέρουν οι Transformers με τη FAISS. Αρχικά, χρησιμοποιούμε την Elasticsearch της φάσης 1 για να εκτελέσουμε μια γρήγορη αναζήτηση με τον BM25. Από τα 18316 κείμενα απομονώνουμε τα $N=200$ πιο σχετικά. Έπειτα, δημιουργούμε ενθέσεις για τα $N=200$ κείμενα που επιστράφηκαν και για το ερώτημα, χρησιμοποιώντας το μοντέλο all-MiniLM-L6-v2 της φάσης 2. Δημιουργούμε δυναμικά ένα ευρετήριο FAISS με τα embeddings των κειμένων και τα ταξινομούμε βάσει συνημιτονοειδούς ομοιότητας. Έτσι, λαμβάνουμε τα $N=200$ πιο σχετικά κείμενα βάσει του BM25 και τα επαναταξινομούμε με σημασιολογική ανάκτηση.

Το $N=200$ επιλέχθηκε ώστε να είναι αρκετά μεγάλο για να περιέχει τα περισσότερα σχετικά έγγραφα, αλλά αρκετά μικρό ώστε η δημιουργία ενθέσεων και η επαναταξινόμηση να γίνονται γρήγορα. Τα $k=20, 30, 50$ επιλέχθηκαν από την εκφώνηση και για να υπάρχει ταύτιση με τις προηγούμενες φάσεις. Επιλέχθηκε το IndexFlatIP μαζί με L2 κανονικοποίηση ώστε να χρησιμοποιηθεί η συνημιτονοειδής ομοιότητα για την τελική κατάταξη των κειμένων.

Η αξιολόγηση του συστήματος πραγματοποιήθηκε χρησιμοποιώντας το εργαλείο trec_eval για να συγκριθούν τα ανακτημένα αποτελέσματα με το δοθέν αρχείο qrels.txt σε τρία βάθη ανάκτησης ($k=20, 30, 50$). Για την εκτέλεση του results_k20, το σύστημα πέτυχε Mean Average Precision (MAP) 0.3634, με Precision@5 0.6800 και Precision@20 0.4000. Όταν το βάθος ανάκτησης αυξήθηκε στο results_k30, το MAP αυξήθηκε στο 0.4250, ενώ οι τιμές Precision@k παρέμειναν σταθερές. Η τελική αξιολόγηση στο results_k50 έφτασε στο υψηλότερο MAP, 0.4708. Αυτή η τάση δείχνει ότι, ενώ η κατάταξη των κορυφαίων

αποτελεσμάτων παραμένει σταθερή, η αύξηση του αριθμού των ανακτημένων εγγράφων βελτιώνει σημαντικά την ανάκληση, καταγράφοντας σχετικά κείμενα που τοποθετήθηκαν χαμηλότερα στη λίστα κατάταξης.

```
C:\Windows\System32\cmd.exe
txt results_k20.txt
3 [main] trec_eval 7492 find_fast_cwd: WARNING: Couldn't compute FAST_CWD pointer. Please report this problem
to
the public mailing list cygwin@cygwin.com
map all 0.3634
P_5 all 0.6800
P_10 all 0.5500
P_15 all 0.4400
P_20 all 0.4000

C:\Users\30695\Desktop\4oETOS\7o6MHN0\Systhmata_Anakthshs\ergasia3\ToRun>trec_eval.exe -m map -m P.5,10,15,20 qrels.
txt results_k30.txt
3 [main] trec_eval 13252 find_fast_cwd: WARNING: Couldn't compute FAST_CWD pointer. Please report this problem
to
the public mailing list cygwin@cygwin.com
map all 0.4250
P_5 all 0.6800
P_10 all 0.5500
P_15 all 0.4400
P_20 all 0.4000

C:\Users\30695\Desktop\4oETOS\7o6MHN0\Systhmata_Anakthshs\ergasia3\ToRun>trec_eval.exe -m map -m P.5,10,15,20 qrels.
txt results_k50.txt
3 [main] trec_eval 2896 find_fast_cwd: WARNING: Couldn't compute FAST_CWD pointer. Please report this problem
to
the public mailing list cygwin@cygwin.com
map all 0.4708
P_5 all 0.6800
P_10 all 0.5500
P_15 all 0.4400
P_20 all 0.4000
```

Πάλι τα αποτελέσματα έδειξαν ότι το μοντέλο δεν είναι εξίσου αποτελεσματικό για κάθε ερώτημα. Τα ερωτήματα Q06 και Q09 είχαν τέλειο MAP στα 5 πρώτα ανακτηθέντα κείμενα. Για κάθε ερώτημα το MAP ήταν υψηλότερο στα 5 πρώτα ανακτηθέντα κείμενα, δείχνοντας ότι το υβριδικό μοντέλο τείνει να ανακτά πρώτα τα πιο σχετικά κείμενα.

```
C:\Windows\System32\cmd.exe
P_20 all 0.4000

C:\Users\30695\Desktop\4oETOS\7o6MHN0\Systhmata_Anakthshs\ergasia3\ToRun>trec_eval.exe -q -m map -m P.5 qrels.txt res
ults_k50.txt
3 [main] trec_eval 4388 find_fast_cwd: WARNING: Couldn't compute FAST_CWD pointer. Please report this problem
to
the public mailing list cygwin@cygwin.com
map Q01 0.4880
P_5 Q01 0.6000
map Q02 0.3149
P_5 Q02 0.4000
map Q03 0.5104
P_5 Q03 0.6000
map Q04 0.5200
P_5 Q04 0.8000
map Q05 0.4506
P_5 Q05 0.6000
map Q06 0.5478
P_5 Q06 1.0000
map Q07 0.4084
P_5 Q07 0.6000
map Q08 0.3274
P_5 Q08 0.6000
map Q09 0.7075
P_5 Q09 1.0000
map Q10 0.4334
P_5 Q10 0.6000
map all 0.4708
P_5 all 0.6800
```

Ενδιαφέρον έχει να αξιολογήσουμε την απόδοση των 3 διαφορετικών υλοποιήσεων. Παρακάτω βλέπουμε το Mean Average Precision για k=5, 10, 15, 20 για κάθε υλοποίηση:

```
C:\Users\30695\Desktop\4oETOS\7o6MHN0\Systhmata_Anakthshs\ergasia1\ToRun>trec_eval.exe -m
map -m P.5,10,15,20 qrels.txt results_k50.txt
  2 [main] trec_eval 1072 find_fast_cwd: WARNING: Couldn't compute FAST_CWD pointer.
Please report this problem to
the public mailing list cygwin@cygwin.com
map          all      0.5685
P_5          all      0.7400
P_10         all      0.6400
P_15         all      0.5867
P_20         all      0.5100
```

Φάση 1 - Κλασική ανάκτηση

```
C:\Users\30695\Desktop\4oETOS\7o6MHN0\Systhmata_Anakthshs\ergasia2\ToRun>trec_eval.exe -m
map -m P.5,10,15,20 qrels.txt results_k50.txt
  1 [main] trec_eval 19116 find_fast_cwd: WARNING: Couldn't compute FAST_CWD pointer.
Please report this problem to
the public mailing list cygwin@cygwin.com
map          all      0.3744
P_5          all      0.6600
P_10         all      0.5000
P_15         all      0.3933
P_20         all      0.3500
```

Φάση 2 - Σημασιολογική ανάκτηση

```
C:\Users\30695\Desktop\4oETOS\7o6MHN0\Systhmata_Anakthshs\ergasia3\ToRun>trec_eval.exe -m
map -m P.5,10,15,20 qrels.txt results_k50.txt
  3 [main] trec_eval 16880 find_fast_cwd: WARNING: Couldn't compute FAST_CWD pointer.
Please report this problem to
the public mailing list cygwin@cygwin.com
map          all      0.4708
P_5          all      0.6800
P_10         all      0.5500
P_15         all      0.4400
P_20         all      0.4000
```

Φάση 3 - Υβριδικό μοντέλο ανάκτησης

Παρατηρούμε ότι, για αυτά τα ερωτήματα και αυτήν την συλλογή κειμένων, η κλασική ανάκτηση υπερτερεί σε κάθε βάθος των άλλων δύο υλοποιήσεων, ενώ το υβριδικό μοντέλο υπερτερεί της σημασιολογικής ανάκτησης. Συγκεκριμένα, η κλασική ανάκτηση υπερτερεί έναντι στο υβριδικό σύστημα ανάκτησης γιατί στην συγκεκριμένη συλλογή κειμένων τα ερωτήματα περιέχουν πολύ εξειδικευμένους όρους, τους οποίους εντοπίζει πολύ καλά ο BM25. Το υβριδικό σύστημα μπορεί να υποβαθμίσει μια λεκτική ταύτιση επειδή συνοπολογίζει και την σημασιολογική ομοιότητα, η οποία ενδέχεται να είναι χαμηλότερη. Από την άλλη, το σημασιολογικό μοντέλο συχνά επέστρεφε άσχετα κείμενα με συναφή θεματολογία, όμως η αρχική χρήση του BM25 περιόρισε την αναζήτηση του Transformer μόνο σε σχετικά κείμενα, με αποτέλεσμα την αύξηση της ακρίβειας.

Συμπερασματικά, βλέπουμε ότι κάθε υλοποίηση έχει τα ανάλογα πλεονεκτήματα και μειονεκτήματα, και η επιλογή μοντέλου ανάκτησης εξαρτάται από παράγοντες όπως το είδος, το μέγεθος της συλλογής κειμένων και την φύση των ερωτημάτων. Στο συγκεκριμένο πρόβλημα το κλασικό σύστημα ανάκτησης με την Elasticsearch και τον BM25 αποδείχθηκε αποδοτικότερο, με το υβριδικό σύστημα να έχει επίσης αξιόλογη απόδοση.

Ως πηγές χρησιμοποιήθηκαν οι διαφάνειες του μαθήματος και το βιβλίο του Manning.